



Introdução Inteligência Computacional

Profa. Dra. Ana Paula Abrantes de Castro e Shiguemori

anapaula.acs@ifsp.edu.br

Instituto Federal de Educação, Ciência e Tecnologia – IFSP

Dr. Elcio Hideiti Shiguemori

elcio@ieav.cta.br

Instituto de Estudos Avançados - IEAv

Curso: Análise e Desenvolvimento de Sistemas
4º. Semestre - IIC14 – 4 aulas Semanais




Perceptron

Roteiro

- Modelo Perceptron
- Treinamento
- Interpretação Geométrica
- Exemplos
- Limitações

Modelo do Neurônio Artificial

O Neurônio artificial é função matemática que associa pesos às entradas.



$$v_k = \sum_{j=1}^n w_{kj} x_j + b_k$$



$$y_k = \varphi(v_k)$$

(McCulloch e Pitts, 1943)

Histórico Perceptron


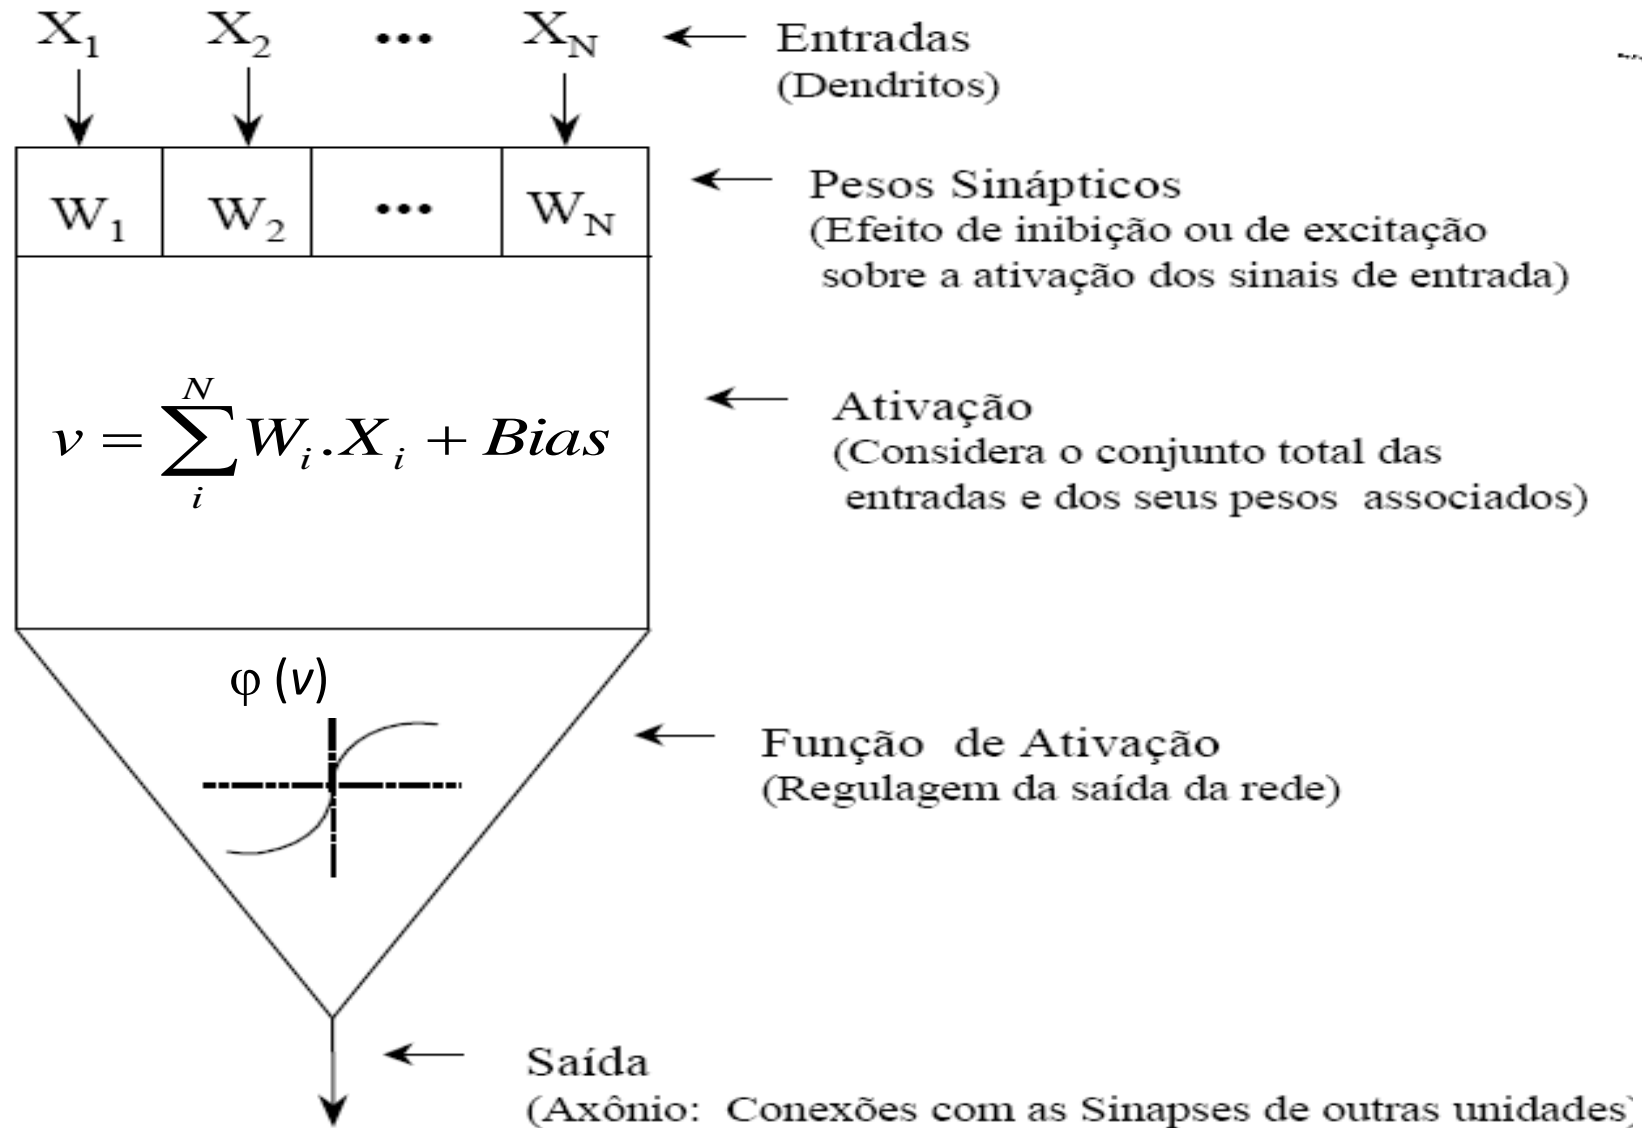
Rosemblat propôs o Perceptron (1958)

- ▶ Como um método inovador de aprendizagem supervisionada
- ▶ Demonstração do teorema da convergência
- ▶ A forma mais simples de uma rede neural usada para classificação de padrões linearmente separáveis

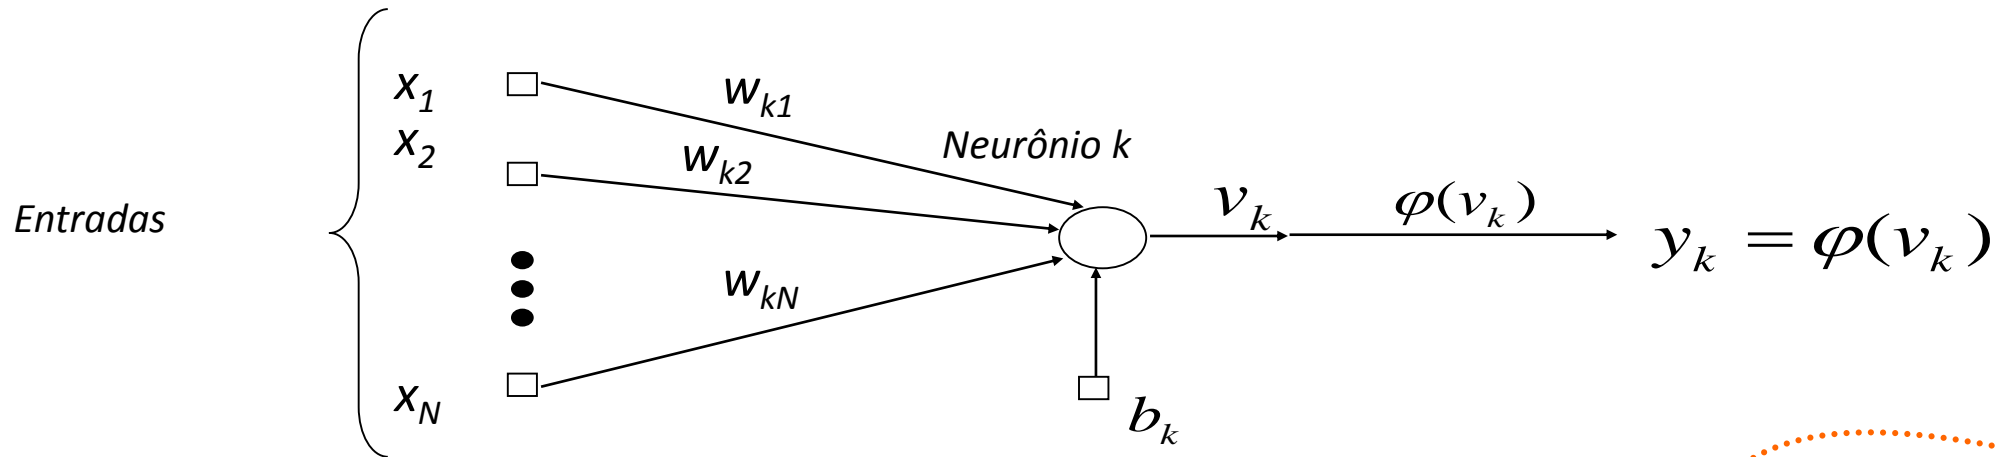
Características

- ▶ Aprendizado supervisionado
- ▶ Representação binária
- ▶ Apenas uma camada de pesos ajustáveis

Modelo do Perceptron



Arquitetura Básica do Perceptron



$$y_k = \varphi\left(\sum_{i=1}^N w_{ki} x_i - b_k\right)$$

$$b_k = 1 \cdot w_{k0}$$

$$\bar{W} = [w_{k0} \quad w_{k1} \quad \dots \quad w_{kN}]$$


$$\bar{X} = \begin{bmatrix} 1 \\ x_1 \\ \vdots \\ x_N \end{bmatrix}$$

$$v_k = \varphi(w_{k1}x_1 + \dots + w_{kN}x_N + (1)w_{k0})$$

$$= \varphi\left(\sum_{i=0}^N w_{ki} x_i\right) = \varphi(\bar{W}^T \bar{X})$$


Fronteira de Decisão

- ▶ Atribuir o ponto representado pelas entradas x_1, x_2, \dots, x_n à classe C_1 se a saída y do Perceptron for igual a 1 ou à classe C_2 se ela for 0
- ▶ O efeito do bias “ b ” é de deslocar a fronteira de decisão em relação à origem



Limitações do Perceptron

- ▶ Não admite mais de uma camada de pesos ajustáveis
- ▶ Aprendizado nem sempre ocorre
- ▶ As duas classes C_1 e C_2 devem ser linearmente separáveis



Algoritmo de Treinamento

Inicialize w

Repita

Para cada padrão x_i faça

$y_i \leftarrow$ valor de saída do perceptron para o padrão x_i

$e \leftarrow d_i - y_i$

$w \leftarrow w + e * \eta * x_i$

fim

Até (o número de interações máximo ser atingido) ou (o perceptron acertar a saída para todos os padrões).

Fim

Algoritmo de Treinamento

Passo 1. Inicializa pesos: $\bar{W}(0) = \bar{0}$

Passo 2. Ativa a rede - vetor de entrada e a resposta desejada: $\bar{X}(n)$ e $d(n)$

Passo 3. Calcula-se a saída: $y(n) = F(\bar{W}^T(n) \bar{X}(n))$ - $F(.)$ é a função sinal

Passo 4. Atualiza os pesos e bias: $\bar{w}(n+1) = \bar{w}(n) + \eta[d(n) - y(n)]\bar{X}(n)$

$$b(n+1) = b(n) + \eta[d(n) - y(n)] * 1$$

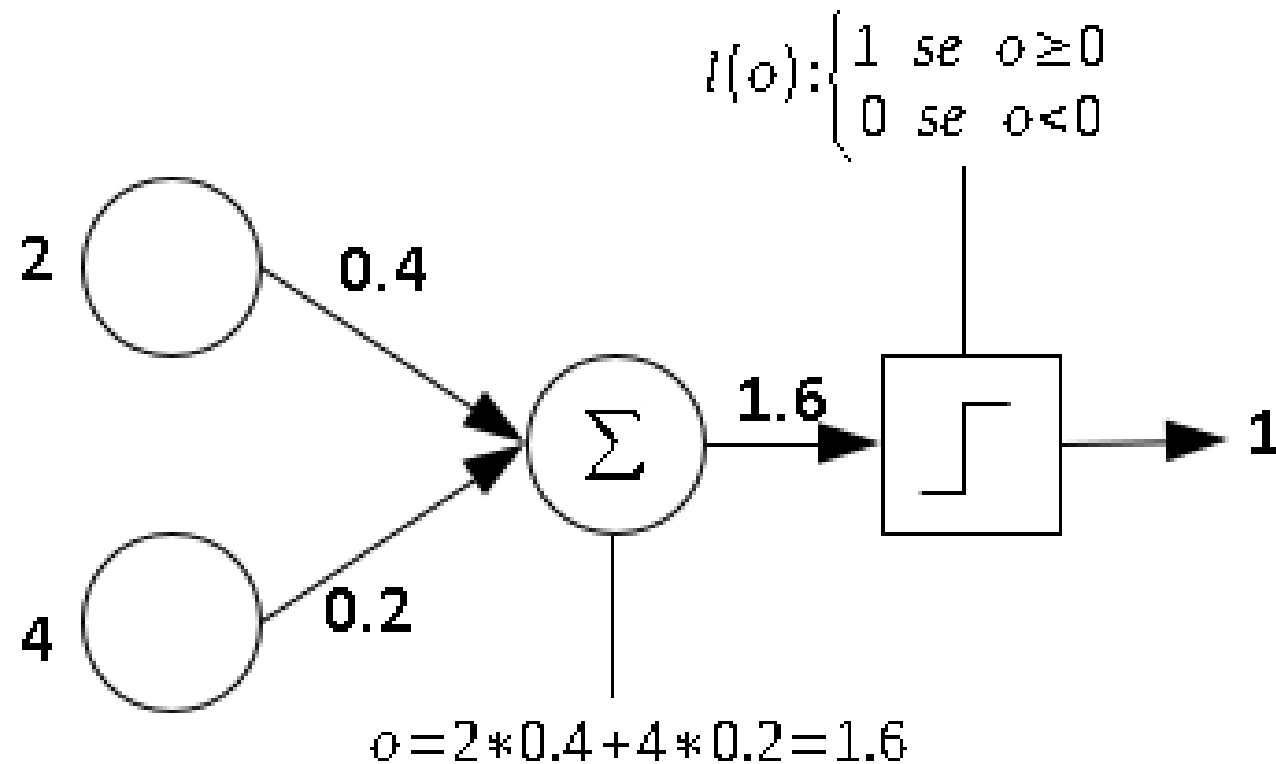
$$d(n) = \begin{cases} +1 & \text{se } \bar{X}(n) \in C_1 \\ -1 & \text{se } \bar{X}(n) \in C_2 \end{cases}$$

Passo 5. Incrementa n e volta para o Passo 2.



Exemplo


$$\begin{aligned}x_1 &= 2 \\x_2 &= 4 \\w_1 &= 0.1 \\w_2 &= 0.2\end{aligned}$$







Exemplo – Classificação 2 Classes

- Treinar o Perceptron para achar um discriminante que divida em duas partes o conjunto de quatro pontos no plano que são Linearmente .



A Iniciando os dados

x	y	Classe
0.3	0.7	1
-0.6	0.3	0
-0.1	-0.8	0
0.1	-0.45	1



Pesos

$$w_1 = 0.8$$

$$w_2 = -0.5$$

Taxa de aprendizagem

$$n = 0.5$$

A Equações de Treinamento

Toda vez que gera uma saída compara com a classe esperada e computa o erro.

$$e = (saida_{desejada} - saida_{rede})$$


Atualização dos pesos

$$\varphi(y) = \begin{cases} 1 & \text{se } o \geq 0 \\ 0 & \text{se } o < 0 \end{cases}$$

Atualização dos pesos

$$w_{new} = w_{old} + nex_i$$

Onde x_i é o elemento correspondente do vetor de input que gerou o erro.



A Primeira Iteração

Entradas: $x_1 = 0.3$ e $x_2 = 0.7 \rightarrow Classe = 1$


Pesos: $w_1 = 0.8$ e $w_2 = -0.5$

Saída: $y_1 = 0.3 * 0.8 + 0.7 * (-0.5) = -0.11$

Função de Ativação: $\varphi(-0.11) = \begin{cases} 1 & \text{se } o \geq 0 \\ 0 & \text{se } o < 0 \end{cases} \rightarrow 0$

Erro: $e_1 = (1 - 0) = 1$

Atualização dos Pesos: $w_1 = 0.8 + 0.5 * 1 * 0.3 = 0.95$
 $w_2 = -0.5 + 0.5 * 1 * 0.7 = -0.15$





Segunda Iteração

Entradas: $x_1 = -0.6$ e $x_2 = 0.3 \rightarrow Classe = 0$


Pesos: $w_1 = 0.95$ e $w_2 = -0.15$

Saída: $y_1 = -0.6 * 0.95 + 0.3 * (-0.15) = -0.525$

Função de Ativação: $\varphi(-0.525) = \begin{cases} 1 & \text{se } o \geq 0 \\ 0 & \text{se } o < 0 \end{cases} \rightarrow 0$

Erro: $e_1 = (0 - 0) = 0$

Classificou de forma correta, não atualiza os pesos





Terceira Iteração

Entradas: $x_1 = -0.1$ e $x_2 = -0.8 \rightarrow Classe = 0$


Pesos: $w_1 = 0.95$ e $w_2 = -0.15$

Saída: $y_1 = -0.1 * 0.95 + (-0.8) * (-0.15) = 0.025$

Função de Ativação: $\varphi(0.025) = \begin{cases} 1 & \text{se } o \geq 0 \\ 0 & \text{se } o < 0 \end{cases} \rightarrow 1$

Erro: $e_1 = (1 - 0) = 1$

Atualização dos Pesos: $w_1 = 0.95 + 0.5 * 1 * (-0.1) = 1$
 $w_2 = -0.15 + 0.5 * 1 * (-0.8) = 0.25$





Quarta Iteração

Entradas: $x_1 = 0.1$ e $x_2 = -0.45 \rightarrow Classe = 1$


Pesos: $w_1 = 1$ e $w_2 = 0.25$

Saída: $y_1 = 0.1 * 1 + (-0.45) * 0.25 = -0.0125$

Função de Ativação: $\varphi(-0.11) = \begin{cases} 1 & \text{se } o \geq 0 \\ 0 & \text{se } o < 0 \end{cases} \rightarrow 0$

Erro: $e_1 = (1 - 0) = 1$

Atualização dos Pesos: $w_1 = 1 + 0.5 * 1 * (0.1) = 1.05$
 $w_2 = 0.25 + 0.5 * 1 * (-0.45) = 0.025$



A Quinta Iteração

Entradas: $x_1 = 0.3$ e $x_2 = 0.7 \rightarrow Classe = 1$


Pesos: $w_1 = 1.05$ e $w_2 = 0.025$

Saída: $y_1 = 0.3 * 1.05 + 0.7 * 0.025 = 0.3325$

Função de Ativação: $\varphi(0.3325) = \begin{cases} 1 & \text{se } o \geq 0 \\ 0 & \text{se } o < 0 \end{cases} \rightarrow 1$

Erro: $e_1 = (1 - 1) = 0$

Classificou de forma correta, não atualiza os pesos





Sexta Iteração

Entradas: $x_1 = -0.6$ e $x_2 = 0.3 \rightarrow Classe = 0$


Pesos: $w_1 = 1.05$ e $w_2 = 0.025$

Saída: $y_1 = -0.6 * 1.05 + 0.3 * 0.025 = -0.6225$

Função de Ativação: $\varphi(-0.6225) = \begin{cases} 1 & \text{se } o \geq 0 \\ 0 & \text{se } o < 0 \end{cases} \rightarrow 0$

Erro: $e_1 = (0 - 0) = 0$

Classificou de forma correta, não atualiza os pesos



A Sétima Iteração

Entradas: $x_1 = -0.1$ e $x_2 = -0.8 \rightarrow Classe = 0$


Pesos: $w_1 = 1.05$ e $w_2 = 0.025$

Saída: $y_1 = -0.1 * 1.05 + (-0.8) * 0.025 = -0.125$

Função de Ativação: $\varphi(-0.125) = \begin{cases} 1 & \text{se } o \geq 0 \\ 0 & \text{se } o < 0 \end{cases} \rightarrow 0$

Erro: $e_1 = (0 - 0) = 0$

Classificou de forma correta, não atualiza os pesos





Oitava Iteração

Entradas: $x_1 = 0.1$ e $x_2 = -0.45 \rightarrow Classe = 1$


Pesos: $w_1 = 1.05$ e $w_2 = 0.025$


Saída: $y_1 = 0.1 * 1.05 + (-0.45) * 0.025 = 0.0937$

Função de Ativação: $\varphi(0.0937) = \begin{cases} 1 & \text{se } o \geq 0 \\ 0 & \text{se } o < 0 \end{cases} \rightarrow 1$


Erro: $e_1 = (1 - 1) = 0$

Classificou de forma correta, não atualiza os pesos







Início



1º. e 2º. Iteração



3º. Iteração



4º. Iteração

A Considerações

- ▶ O perceptron só é capaz de separar classes através de funções lineares.
- ▶ As classes têm que ser linearmente separáveis, o que é uma condição não garantida para a maioria dos problemas de classificação
- ▶ Resolve o problema da porta AND e OR, por serem linearmente separáveis
- ▶ Não Resolve o problema da porta XOR, por não ser linearmente separável

A Exercício

► Faça o treinamento da Rede Perceptron para o problema da porta lógica AND.

x	y	Classe
0	0	0
0	1	0
1	0	0
1	1	1



Dúvidas?



Referências Bibliográficas

- José Demísio Simões da Silva – Notas de Aula
- Ana Paula A. C. Shiguemori – Notas de Aula
- Elcio Hideiti Shiguemori – Notas de Aula